

DeepGxP 课程实践项目：90 个讨论问题回答总文档

课程实践项目 1：Predicting and interpreting protein and phosphoprotein abundance

2026 年 6 月 16 日

目录

使用说明	2
1 一、数据理解与任务定义	3
2 二、模型训练、基线与消融	6
3 三、训练质控与统计评价	10
4 四、统计检验、结果解释与泛化分析	13
5 五、结果可视化与课堂讨论	17
6 六、综合讨论题	20
结语	23

使用说明

本文档按照老师 PPT 中的 90 个讨论问题组织，覆盖数据理解、模型训练、统计评价、结果解释、可视化和综合讨论。回答采用“课程项目可直接使用”的写法：先给出明确结论，再补充必要的机器学习、统计学和生物学解释。建议使用 XeLaTeX 编译。

1 一、数据理解与任务定义

1. 如何将本文任务形式化为 $X \rightarrow Y$ 的监督学习问题？

回答： 本文任务可以形式化为一个监督学习回归问题。输入 X 是样本的 RNA 表达矩阵，每一行对应一个样本或一个细胞，每一列对应一个基因表达量；输出 Y 是蛋白丰度矩阵，每一行与 X 中样本一一对应，每一列对应一个蛋白或磷酸化蛋白丰度。DeepGxP 学习的函数可以写成 $f_{\theta}: X \rightarrow Y$ ，即利用全转录组表达模式预测蛋白层信息。bulk 任务中，输入是 TCGA 泛癌 bulk RNA-seq，标签是 RPPA 测得的总蛋白和磷酸化蛋白；单细胞任务中，输入是 scRNA-seq，标签是 CITE-seq/ADT 表面蛋白。该任务的本质不是分类，而是多输出连续值预测。

2. bulk RNA $\rightarrow$ protein 任务中， X 的行和列分别代表什么？

回答： 在 bulk RNA $\rightarrow$ protein 任务中， X 是一个样本乘基因的表达矩阵。行代表肿瘤样本，例如 TCGA 中具有配对 RNA 和 RPPA 蛋白测量的实体瘤样本；列代表基因，例如筛选后的约 13,995 个基因表达特征。矩阵元素 x_{ij} 表示第 i 个样本中第 j 个基因的表达水平。模型把每个样本的一整行全转录组表达作为输入，预测该样本对应的多个蛋白丰度。

3. 输出标签 Y 是单一蛋白还是多个蛋白？对建模有什么影响？

回答： 本文的 bulk 任务中， Y 是多个蛋白的输出标签，而不是单一蛋白。DeepGxP 一次性预测 187 个蛋白和磷酸化蛋白丰度，因此是多输出回归。多输出建模的好处是不同蛋白之间可能共享上游转录调控、细胞状态和通路信息，模型可以在同一个表示空间中学习这些共同结构；同时，输出层需要有多个节点，每个节点对应一个蛋白。缺点是标签缺失、蛋白间尺度差异和不同蛋白预测难度差异都会使训练更复杂。

4. 样本缺少部分蛋白标签时，训练时应如何处理？

回答： 如果一个样本缺少部分蛋白标签，不能简单把缺失值当成 0，因为 0 会被模型误认为真实低表达。常见处理方式有三类：第一，只保留完整配对的样本和蛋白，用完整标签训练；第二，对每个蛋白单独定义可用样本，在计算损失时使用 mask，只对非缺失标签计算损失；第三，在缺失比例较低且有合理假设时进行插补，但这种做法需要谨慎。本文为了保证监督标签可靠，主要使用具有配对 mRNA-蛋白测量的数据，并通过蛋白筛选保证标签质量。复现时，最稳妥的教学方案是先保留完整标签或使用 masked loss。

5. 为什么要过滤低表达或低变异基因？

回答： 过滤低表达或低变异基因是为了降低噪声、减少无效特征并提升训练稳定性。低表达基因通常接近测序检测下限，容易受到技术噪声影响；低变异基因在不同样本之间几乎不变化，对区分蛋白丰度差异贡献有限。保留大量这类基因会增加输入维度、提高计算成本、加重过拟合风险，还可能稀释真正有用的调控信号。因此，本文去除平均表达低且标准差低的基因，同时保留编码目标蛋白的 self-gene，以避免丢掉重要生物学参照。

6. 不过滤低表达基因可能带来哪些训练问题？

回答： 不进行过滤会带来几个问题。第一，输入维度过高，参数学习更困难，计算开销增大。第二，低表达基因的测量误差相对更高，会把噪声输入模型。第三，大量无信息特征可能使模型学习到偶然相关，导致过拟合。第四，梯度更新可能被无效特征分散，使模型更难聚焦于真正与蛋白丰度相关的调控基因。对于样本量有限的生物医学数据，高维低信噪比是非常典型的问题，因此基因过滤是必要的预处理步骤。

7. RNA 表达和蛋白丰度为什么需要标准化？

回答： RNA 表达和蛋白丰度的量纲、分布和取值范围不同，如果不标准化，模型可能优先关注数值范围较大的特征或输出，而不是生物学上更重要的变化。对 RNA 特征标准化可以使不同基因在模型输入中具有可比尺度，改善梯度下降稳定性；对蛋白标签标准化可以避免某些高方差蛋白主导损失函数。本文对表达值进行 z 转换，使每个基因表达在均值和方差层面更可比较。标准化还有助于 Pearson 相关、MSE 等评价指标的解释。

8. bulk 数据和 CITE-seq 单细胞数据在噪声和稀疏性上有何不同？

回答： Bulk 数据测量的是大量细胞的平均表达，因此单个样本的表达矩阵相对平滑，掉零现象较少，但会掩盖细胞类型组成和细胞状态差异。CITE-seq 单细胞数据在单个细胞层面测量 RNA 和表面蛋白，能观察细胞异质性，但 RNA 表达高度稀疏，dropout 更明显，批次效应和技术噪声更强。正因如此，单细胞版 DeepGxP 在 SCTransform 归一化后加入 MAGIC 插补，并减少卷积核数量，以适应更稀疏、更噪声化的数据。

9. 为什么不能把 TCGA 和 ICGC 混合后随机划分训练/测试？

回答： 如果把 TCGA 和 ICGC 混合后随机划分，外部验证的意义会被破坏。TCGA 和 ICGC 来自不同队列，可能存在平台、样本来源、处理流程和人群结构差异。外部验证的目的正是检验模型在独立数据分布上的泛化能力。如果混合随机划分，训练集和测试集都会包含两个队列的信息，模型可能利用队列共同偏差获得较高测试性能，却不能证明其能迁

移到真正独立的数据集。因此，TCGA 应主要用于模型开发和内部评估，ICGC 应保留为外部验证集。

10. 复现本文核心实验，最小可行数据集需要哪些表格？

回答： 最小可行复现实验至少需要四类表格。第一，RNA 表达矩阵：样本乘基因，作为模型输入。第二，蛋白丰度矩阵：样本乘蛋白，作为监督标签。第三，样本注释表：包括样本 ID、癌种、队列来源、训练/验证/测试划分等信息，用于配对和分层分析。第四，基因与蛋白对应关系表：用于确定 self-gene baseline 以及蛋白筛选。若要复现生存分析，还需要临床生存信息表；若要复现单细胞部分，还需要细胞乘基因矩阵、细胞乘 ADT 蛋白矩阵和细胞类型注释表。

11. train、validation、test 在模型训练中分别起什么作用？

回答： 训练集用于更新模型参数，即通过反向传播和优化器最小化损失函数。验证集不参与参数更新，主要用于调参、选择模型结构、监控过拟合和执行 early stopping。测试集只在最终模型确定后使用，用于估计模型在未见数据上的泛化性能。三者的核心区别是参与决策的程度不同：train 用于学习，validation 用于选择，test 用于最终评估。若在调参过程中反复查看 test 结果，就会造成测试集泄漏，使最终性能估计偏乐观。

12. 10-fold cross-validation 与普通 train/test split 有何不同？

回答： 普通 train/test split 只进行一次数据划分，模型性能可能受到随机划分的影响。10-fold cross-validation 将数据分成 10 份，每次用 9 份训练、1 份测试，循环 10 次，使每个样本都有一次作为测试样本的机会。最后对 10 次结果求平均和标准差。交叉验证比单次划分更能反映模型稳定性，尤其适用于样本量有限或不同模型差异不大时的比较。本文用 10-fold CV 比较 DeepGxP 与 XGB、SVM、VAE、ResNet 等模型，增强了模型比较的可信度。

13. 交叉验证为什么能更稳定地评估模型性能？

回答： 交叉验证通过多次训练和测试减少了单次随机划分带来的偶然性。一次 train/test split 可能刚好把容易预测的样本分到测试集，或者把某些癌种分布不均衡地分入训练集，从而导致性能估计偏高或偏低。交叉验证让不同样本轮流进入测试集，最后报告平均值和波动范围，因此更能反映模型在整体数据上的稳定表现。标准差也能提示模型对数据划分是否敏感。

14. 外部验证集和内部测试集最大的区别是什么？

回答： 内部测试集通常与训练集来自同一数据来源，只是在样本层面没有参与训练；外部验证集来自独立队列、平台或研究项目，数据分布可能不同。内部测试主要检验模型是否能泛化到同一数据分布下的未见样本，外部验证则检验模型是否能跨队列、跨平台或跨人群迁移。本文中 TCGA 内部测试说明模型在 TCGA 分布下有效，ICGC 外部验证进一步说明模型不是只记住 TCGA，而具有一定泛化能力。

15. 模型内部测试好、外部验证差，可能说明什么？

回答： 这种情况通常说明模型泛化能力不足。可能原因包括：训练集和外部验证集存在平台差异、样本组成差异、癌种比例差异或预处理流程不一致；模型过拟合了训练队列的特定噪声；训练集包含的数据范围不足，无法覆盖外部队列；也可能是标签测量平台不一致导致蛋白丰度不可直接比较。遇到这种情况，应检查批次效应、特征对齐、标准化方式、样本分布和标签一致性，并考虑域适应、分癌种建模或更严格的外部校准。

16. 如何避免预处理阶段发生训练集与测试集信息泄漏？

回答： 避免信息泄漏的原则是：任何需要估计参数的预处理步骤，都只能在训练集上拟合，再应用到验证集和测试集。例如标准化的均值和标准差应从训练集计算，不能用全数据计算；特征筛选、缺失值插补、批次校正和降维也应在训练折内完成。交叉验证时，每一折都要独立执行预处理流程，不能先对全体样本做筛选再划分。否则测试集信息会间接进入训练过程，导致模型性能虚高。

2 二、模型训练、基线与消融

17. DeepGxP 是分类模型还是回归模型？判断依据是什么？

回答： DeepGxP 是回归模型，不是分类模型。判断依据是它的输出标签是连续的蛋白丰度或磷酸化蛋白丰度，而不是离散类别。模型输出层使用线性激活，输出多个连续数值，并用 MSE、Pearson 相关等回归指标评价预测值与真实蛋白丰度的一致性。如果任务是判断癌种类型或细胞类型，才属于分类；本文的主任务是预测数值型蛋白水平，因此属于多输出回归。

18. 多输出回归相比单输出回归有什么优势？

回答： 多输出回归可以同时预测多个蛋白，优势在于共享表示和提升计算效率。多个蛋白可能受共同细胞状态、通路活性、癌种背景和转录调控网络影响，多输出模型可以在共享

隐藏层中学习这些共同因素。相比为每个蛋白单独训练模型，多输出模型参数更集中，训练和推理更高效，也更容易捕捉蛋白之间的关联。风险是不同蛋白预测难度不同，简单共享可能导致某些蛋白受其他任务干扰，因此需要合理的损失设计和输出标准化。

19. 每个蛋白单独训练一个模型有什么优缺点？

回答： 单蛋白模型的优点是任务更简单，可以针对每个蛋白选择最合适的特征、模型复杂度和超参数，解释结果也更直接；如果不同蛋白调控机制差异很大，单独建模可能更灵活。缺点是需要训练大量模型，计算成本高，不能共享不同蛋白之间的通路和细胞状态信息，而且对于样本量有限的蛋白更容易过拟合。本文采用多输出 DeepGxP，是为了用统一模型学习全转录组到多蛋白丰度的系统性映射。

20. 1D-CNN 用于基因表达数据时可能学习到什么模式？

回答： 1D-CNN 可以从按某种顺序排列的基因表达向量中学习局部组合特征，再通过后续层整合成全局表示。在基因表达任务中，它可能学习到共表达模块、通路相关基因组合、局部排列中相邻基因的联合模式，以及与蛋白丰度相关的非线性表达特征。但需要注意，基因表达数据不像图像或文本天然具有稳定局部邻域结构，所以 CNN 学到的模式是否具有明确生物学局部性，取决于基因排序方式和模型解释的谨慎程度。

21. 基因排列顺序是否会影响 CNN 的模型解释？

回答： 会。CNN 的卷积操作默认相邻位置之间存在局部关系，因此基因排列顺序会影响哪些基因被同一个卷积核共同处理。如果基因顺序按照染色体位置、通路、共表达模块或其他生物学原则排列，局部卷积可能具有一定解释意义；如果基因顺序基本任意，那么卷积捕捉到的“局部模式”未必对应真实生物学邻近关系。这并不一定使模型无效，但会降低对卷积局部特征的直接生物学解释能力。因此解释 DeepGxP 时，更可靠的是结合 Integrated Gradients 和通路富集，而不是单独解释卷积核邻域。

22. 如果基因顺序任意，CNN 的局部卷积假设是否合理？

回答： 如果基因顺序完全任意，CNN 的局部卷积假设在生物学上并不天然合理，因为相邻输入位置不一定代表相关基因。但 CNN 仍可能作为一种参数共享的非线性特征提取器发挥作用，学习局部组合和稀疏模式。问题在于，这种局部组合不一定有可解释的生物学含义。更严格的做法是比较不同基因排序、随机排序、MLP、Transformer 或 GNN 的性能，并检查解释结果是否稳定。如果随机排序下性能相近，说明 CNN 的优势可能更多来自模型容量和正则化结构，而不是基因局部性。

23. 如果用 MLP 替代 1D-CNN，可能出现什么变化？

回答： MLP 可以直接处理全基因表达向量，不依赖基因顺序，因此避免了 CNN 局部邻域假设的问题。它能学习非线性关系，但参数量可能很大，尤其在输入基因数上万而样本数只有几千时，容易过拟合。CNN 通过卷积核共享参数，在一定程度上降低参数复杂度并提取局部组合特征。若用 MLP 替代，可能提高灵活性，但需要更强正则化、降维或特征选择。实验上应比较 MLP 与 CNN 的 Pearson、MSE、外部验证表现和解释稳定性。

24. 如果用 Transformer 替代 CNN，有哪些优势和风险？

回答： Transformer 的优势是可以通过注意力机制建模任意基因之间的长程依赖，不受局部卷积窗口限制，也更适合捕捉通路级或跨模块调控关系。它还可以引入基因嵌入、通路先验或多组学 token，扩展能力强。风险是参数量大、训练成本高，对样本量要求更高，在几千个 bulk 样本上容易过拟合；注意力权重也不一定等于可靠解释。对于本文任务，Transformer 是有潜力的扩展方向，但必须通过严格基线、外部验证和消融实验来证明其优势，而不能仅凭模型更先进就假定更好。

25. 为什么深度学习可能比线性回归捕捉更复杂的 RNA-protein 关系？

回答： RNA 到蛋白的关系受到翻译效率、蛋白降解、蛋白稳定性、磷酸化、通路活性和多基因调控共同影响，通常不是简单一对一线性关系。线性回归只能表示输入特征的线性加权，难以表达基因间交互和非线性调控。深度学习模型通过多层非线性变换，可以学习复杂表达模式、组合特征和通路级状态，因此更可能从全转录组中捕捉到蛋白丰度的间接调控信号。本文中 DeepGxP 对 low-sGP 和磷酸化蛋白提升更明显，正说明复杂调控蛋白更受益于非线性全转录组建模。

26. 模型复杂度增加时，为什么过拟合风险会上升？

回答： 模型越复杂，参数越多，表达能力越强，越可能把训练数据中的噪声、批次效应或偶然相关也学进去。生物医学数据常见特点是特征维度高、样本量相对有限，如果模型容量远大于有效样本信息，就可能在训练集表现很好，在验证集或外部数据集表现下降。过拟合风险可通过验证集监控、early stopping、dropout、weight decay、交叉验证、外部验证和负对照实验来控制。

27. self-gene baseline 的作用是什么？

回答： self-gene baseline 用对应基因的 mRNA 表达直接代表或预测对应蛋白丰度，是最朴素、最常用的参照。它回答的问题是：如果只看该蛋白自己的 mRNA，能解释多少蛋白变

化？DeepGxP 若显著超过 self-gene baseline，就说明全转录组表达中包含超出单个 mRNA 的额外调控信息。本文中 self-gene/protein 的中位相关性约为 0.31，而 DeepGxP 预测与真实蛋白的中位相关性约为 0.68，直接支持全转录组模型优于简单 mRNA 代理。

28. LR、mLR 和 CCA 分别适合作为什么类型的基线？

回答： LR 适合作为单基因线性基线，通常用 self-gene mRNA 预测对应蛋白，检验“一对一线性关系”有多强。mLR 是多基因线性基线，用多个基因表达线性组合预测蛋白，检验“全转录组信息但线性建模”的效果。CCA 是多组学线性关联基线，用于寻找 RNA 矩阵和蛋白矩阵之间最大相关的线性投影，代表整体线性对应关系。三者共同用于判断 DeepGxP 的优势究竟是否超过单基因、多基因线性和多组学线性关联。

29. XGBoost 和 SVM 作为基线各代表什么建模思路？

回答： XGBoost 代表基于决策树集成的非线性机器学习思路，通过逐步拟合残差来捕捉特征交互和非线性关系，在表格型数据上通常很强。SVM 代表最大间隔和核方法思路，可以通过核函数在高维空间中建模非线性关系，适合中小规模样本。二者都不是深度神经网络，但能提供强传统机器学习基线。DeepGxP 超过它们，说明其性能并非只是因为用了非线性模型，而可能来自更适合多输出 RNA→protein 任务的结构设计。

30. Y-scrambling 是什么？如何判断模型是否学到真实信号？

回答： Y-scrambling 是标签打乱负对照。做法是保持 RNA 输入 X 不变，将蛋白标签 Y 在样本间随机置换，破坏真实 RNA-蛋白配对关系，然后重新训练或评估模型。如果模型确实学到了真实生物学信号，标签打乱后性能应明显下降，Pearson 应接近随机水平。如果 Y-scrambling 仍表现很高，就说明可能存在数据泄漏、样本重复、预处理错误或评价流程问题。本文把 Y-scrambling 作为负对照，用于支持模型不是在随机标签上得到虚假性能。

31. 如果 Y-scrambling 也有较高性能，可能说明什么问题？

回答： 如果 Y-scrambling 后仍有较高性能，首先应怀疑数据泄漏。例如训练集和测试集样本没有严格分离，标准化或特征筛选使用了全数据，或者标签置换没有真正打乱配对。其次，可能存在样本重复、批次标签与蛋白标签高度耦合，模型利用了非生物学结构。也可能是评价代码错误，例如预测值和真实值索引错位但仍被错误对齐。总之，Y-scrambling 高性能是严重警告，说明模型结果不能被直接信任，需要系统排查数据管线。

32. no-self-gene 消融实验可以回答什么问题？

回答： no-self-gene 消融是指在预测某个蛋白时，从输入特征中去掉其对应的 self-gene mRNA，再观察模型性能变化。它可以回答：DeepGxP 的预测是否主要依赖对应 mRNA，还是能从其他基因和全局调控网络中获得信息。如果去掉 self-gene 后性能大幅下降，说明该蛋白主要由自身 mRNA 解释；如果性能仍较好，说明模型捕捉到了其他调控基因、通路状态或细胞状态信息。该实验对 low-sGP 蛋白和磷酸化蛋白尤其重要，因为它们理论上更依赖间接调控信息。

3 三、训练质控与统计评价

33. 模型训练时为什么需要 validation set？

回答： Validation set 用于在训练过程中评估模型对未参与参数更新样本的表现，从而指导超参数选择、模型结构选择和 early stopping。训练集 loss 只能说明模型拟合训练数据的能力，不能可靠反映泛化能力。验证集可以帮助发现过拟合：如果训练集 loss 持续下降而验证集 loss 不再下降甚至上升，就说明模型开始学习训练噪声。没有验证集，研究者容易在测试集上反复调参，导致测试集泄漏。

34. early stopping 如何防止过拟合？

回答： Early stopping 会持续监控验证集指标，例如 validation loss 或 validation Pearson。当训练集性能继续提升但验证集性能不再改善时，训练会提前停止，并保留验证集表现最好的模型参数。这样可以避免模型在后期过度拟合训练集噪声。它本质上是一种正则化方法，通过限制训练时间控制模型复杂度。对于高维组学数据，early stopping 很重要，因为模型很容易在训练集上持续降低误差却损害外部泛化。

35. batch size 过大或过小分别可能带来什么问题？

回答： Batch size 过大时，梯度估计更稳定，训练速度可能更快，但显存占用增加，梯度噪声减少后可能更容易收敛到泛化较差的解；同时更新次数变少，早期探索能力下降。Batch size 过小时，梯度噪声较大，可能有助于跳出局部区域，但训练不稳定，loss 波动大，收敛速度慢，硬件利用率也可能较低。合适 batch size 需要结合样本量、显存、学习率和验证集表现调整。

36. learning rate 过大或过小会如何影响训练？

回答： Learning rate 过大时，参数更新步长过大，loss 可能震荡甚至发散，模型无法稳定收敛；即使收敛，也可能越过较优解。Learning rate 过小时，训练非常慢，容易停留在次优区域，在有限训练轮数内无法充分学习。实践中通常使用验证集监控，并结合学习率衰减、warmup 或自适应优化器。复现论文时，学习率是最需要记录和固定的超参数之一。

37. dropout、weight decay 等正则化方法的作用是什么？

回答： Dropout 在训练时随机屏蔽部分神经元，迫使模型不能依赖少数特征或路径，从而提升鲁棒性。Weight decay 通过惩罚过大的权重限制模型复杂度，使模型倾向于更平滑、更简单的函数。二者都用于降低过拟合风险。对于 RNA 表达这类高维输入，正则化尤其重要，因为基因数远多于常规表格任务，模型容易学习偶然相关。正则化的强度需要通过验证集调节，过强会导致欠拟合。

38. 为什么需要固定 random seed？

回答： 固定 random seed 可以提高实验可复现性。深度学习训练中，随机性来自参数初始化、数据划分、mini-batch 顺序、dropout 和某些 GPU 运算。不同随机种子可能导致模型收敛到不同结果，尤其在样本量有限时差异更明显。固定 seed 能让别人更容易复现同一实验，也便于排查结果变化到底来自代码修改、数据变化还是随机波动。严谨做法是既固定 seed，又报告多个 seed 的平均性能和标准差。

39. 为什么要保存训练日志、模型参数和预测结果？

回答： 训练日志记录 loss、指标、学习率和每轮验证表现，便于判断模型是否收敛或过拟合。模型参数用于复现实验、继续训练和外部验证。预测结果用于计算各种评价指标、绘图、分层分析、生存分析和后续错误分析。没有这些文件，实验结果很难追踪，也无法解释为什么某次训练表现异常。科研项目中，保存日志、参数和预测值是保证可复现性的基本要求。

40. 复现结果与论文不一致时，应从哪些方面排查？

回答： 应按数据、预处理、划分、模型、训练和评价六个层面排查。数据层面检查样本数量、基因数量、蛋白筛选和 ID 对齐；预处理层面检查标准化、缺失值、过滤阈值和批次处理；划分层面检查 train/validation/test 是否与论文一致；模型层面检查卷积核数量、kernel size、stride、激活函数、输出维度；训练层面检查学习率、batch size、epoch、seed、early

stopping；评价层面检查 Pearson 是按蛋白算还是按样本算、是否使用相同测试集。很多复现差异来自索引错位和预处理泄漏。

41. 如何判断模型训练是否出现过拟合？

回答： 最直接的判断是训练集性能持续提升，而验证集或测试集性能停滞或下降。例如训练 loss 下降，验证 loss 上升；训练 Pearson 很高，外部验证 Pearson 明显低。还可以看不同交叉验证折之间波动是否很大、Y-scrambling 是否异常、模型在外部队列是否失败。如果模型参数很多而训练样本有限，也应提高警惕。处理方式包括减小模型、增加正则化、early stopping、数据增强、特征筛选和更严格外部验证。

42. 训练集 loss 下降而验证集 loss 上升，应如何处理？

回答： 这通常是过拟合信号。首先应启用 early stopping，回滚到验证集表现最好的 epoch。其次可以增加 dropout、weight decay，降低模型复杂度或减少训练轮数。还可以检查训练/验证分布是否一致、标准化是否只在训练集拟合、标签是否有异常值。如果验证集太小或划分不均衡，也可以使用交叉验证获得更稳定估计。不能只根据训练 loss 继续训练，因为那会进一步降低泛化能力。

43. Pearson correlation 在蛋白丰度预测中衡量什么？

回答： Pearson correlation 衡量预测蛋白丰度与真实蛋白丰度之间的线性一致性，主要反映样本排序和变化趋势是否一致。对某个蛋白而言，如果 Pearson 高，说明模型能较好地区分哪些样本蛋白丰度高、哪些样本低。本文常按每个蛋白计算预测值与真实值的 Pearson，再报告 187 个蛋白的分布或中位数。Pearson 适合评估相对变化，但不直接等同于绝对误差。

44. Pearson 高是否一定代表预测误差小？为什么？

回答： 不一定。Pearson 对线性缩放和平移不敏感。如果预测值与真实值排序高度一致，但整体偏高、偏低或幅度不准，Pearson 仍可能很高，而 MSE 可能较大。例如 $\hat{y} = 2y + 5$ 的 Pearson 可接近 1，但绝对数值误差明显。因此 Pearson 衡量趋势一致性，MSE 衡量数值接近程度。蛋白丰度预测应同时报告 Pearson 和 MSE，避免只看到排序正确而忽略校准误差。

45. MSE 衡量什么？与 Pearson 有何互补关系？

回答： MSE 即均方误差，衡量预测值与真实值之间的平均平方差，越小表示数值越接近真实丰度。它对绝对偏差和离群点敏感。Pearson 衡量线性相关和排序趋势，不关心整体偏移和缩放。两者互补：Pearson 高说明模型能捕捉样本间相对变化，MSE 低说明模型数值校准较好。一个模型可能 Pearson 高但 MSE 不低，也可能 MSE 低但对高低排序区分不够。因此回归任务需要联合使用。

46. 预测值整体偏高但排序正确，Pearson 和 MSE 会如何表现？

回答： 如果预测值整体偏高但样本排序基本正确，Pearson 可能仍然较高，因为它主要关注线性趋势和相对变化；但 MSE 会变大，因为每个样本的绝对预测值都偏离真实值。这种情况说明模型有较好的排序能力，但校准不足。若下游任务是风险排序或分组，Pearson 可能更相关；若要估计真实蛋白丰度数值或跨队列比较，MSE 和校准就更重要。

47. 为什么要报告每个蛋白的相关性分布，而不只报告平均值？

回答： 不同蛋白的预测难度差异很大。只报告平均值会掩盖模型在某些蛋白上表现很好、某些蛋白上表现很差的事实。相关性分布可以显示整体偏移、离散程度、低性能蛋白比例和异常值，有助于判断模型是否普遍有效，还是只被少数容易预测的蛋白拉高平均值。本文报告每个蛋白的 Pearson 分布，并区分 high-sGP、low-sGP、total protein 和 phosphoprotein，有助于解释模型适用边界。

48. median Pearson 相比 mean Pearson 有什么优点？

回答： Median Pearson 对极端值更稳健。如果少数蛋白预测特别好或特别差，mean 会被明显拉动，而 median 更能代表典型蛋白的表现。生物学多输出任务中，不同蛋白的相关性分布常常偏态，使用中位数能减少离群蛋白影响。因此本文常报告 median Pearson，例如 bulk 测试集中 DeepGxP 中位 Pearson 约 0.68，ICGC 外部验证约 0.60，单细胞 CITE-seq 约 0.576。

4 四、统计检验、结果解释与泛化分析

49. 为什么模型比较中要报告标准差或误差线？

回答： 标准差或误差线表示模型性能在不同交叉验证折、随机种子或重复实验中的波动。如果两个模型平均性能接近，但一个误差线很大，说明其结果不稳定，对数据划分或随机

初始化敏感。只报告平均值会掩盖这种不确定性。本文在 10-fold CV 中报告均值和标准差，用于说明 DeepGxP 不仅平均表现更高，而且在重复划分中相对稳定。

50. $\Delta\rho$ 如何衡量 DeepGxP 相比 self-gene 的提升？

回答： $\Delta\rho$ 定义为 $\rho_{\text{DeepGxP}} - \rho_{\text{self}}$ ，其中 ρ_{DeepGxP} 是模型预测蛋白与真实蛋白的相关性， ρ_{self} 是对应 mRNA 与真实蛋白的相关性。它直接量化 DeepGxP 相比“只用自身 mRNA”多解释了多少蛋白变化。若 $\Delta\rho > 0$ ，说明全转录组模型优于 self-gene；若 low-sGP 或磷酸化蛋白的 $\Delta\rho$ 更大，说明这些蛋白更依赖复杂调控信息。

51. 多蛋白预测中，表现特别差的蛋白应如何处理？

回答： 表现特别差的蛋白不应简单删除，而应先分析原因。可能原因包括标签测量噪声高、RPPA 抗体质量差、该蛋白主要受非 RNA 因素调控、样本中表达变异太低、癌种特异性强或训练样本不足。处理方式包括检查标签质量、分癌种评估、查看 self-gene correlation、进行外部验证、尝试加入 mutation/CNV/methylation 等多组学特征。如果在多个验证集中都无法预测，应在报告中明确列为模型适用边界，而不是强行解释。

52. 预测相关性为负的蛋白应如何解释？

回答： 负相关表示模型预测值与真实蛋白变化方向相反，通常说明模型对该蛋白没有学到有效关系，甚至可能学到了错误的队列偏差或噪声。首先应检查数据对齐、蛋白标签方向、标准化和评估代码是否有问题。若技术上无误，则可能说明该蛋白的丰度与 RNA 表达关系非常弱，或主要受蛋白降解、翻译后修饰、细胞组成等因素影响。负相关蛋白应单独报告，不宜纳入“模型有效”的主要证据。

53. Mann-Whitney test 适合比较什么类型的数据？

回答： Mann-Whitney test 是非参数独立样本检验，适合比较两个独立组的数值分布是否存在差异，不要求数据服从正态分布。例如比较 DeepGxP 预测相关性分布与 random/self-gene 相关性分布，或者比较 total protein 与 phosphoprotein 的提升幅度。它适合蛋白相关性这类可能非正态、带离群值的数据。需要注意，它比较的是分布差异，不只是均值差异。

54. Wilcoxon signed-rank test 适合什么配对比较？

回答： Wilcoxon signed-rank test 是非参数配对检验，适合同一对象在两种方法下的结果比较。例如同一批蛋白在 ICGC 数据中，DeepGxP 预测相关性与 self-gene 相关性可以成

对比较；同一个蛋白有两个方法的表现，差值构成配对数据。它不要求差值服从正态分布，适合生物医学小样本或偏态分布场景。

55. paired t test 为什么常用于交叉验证模型比较？

回答： 在交叉验证中，不同模型通常在相同的数据划分上评估，因此每一折的性能可以成对比较。Paired t test 利用每一折中两个模型性能的差值，检验平均差值是否显著不为 0。由于配对设计消除了不同划分本身难度差异的影响，比独立 t test 更合适。本文用 paired one-tailed t test 比较 DeepGxP 与 XGB、SVM、VAE、ResNet 等模型，检验 DeepGxP 是否在相同 CV 设置下显著更好。

56. 单侧检验和双侧检验有什么区别？何时需谨慎？

回答： 单侧检验只检验差异是否朝预设方向发生，例如 DeepGxP 是否优于基线；双侧检验检验是否存在任意方向差异。单侧检验统计功效更高，但前提是方向必须在实验前明确且有充分理由。若研究者事后看到结果再选择单侧检验，会增加假阳性风险。因此在课程项目中应说明为什么使用单侧或双侧。模型性能比较若明确假设新模型更好，可使用单侧；探索性分组差异更适合双侧。

57. P 值很小是否一定代表模型提升有实际意义？

回答： 不一定。P 值很小只说明在零假设下观察到当前差异的概率很低，受样本量影响很大。若蛋白数量或重复次数很多，即使提升幅度很小也可能显著。实际意义需要看效应量、绝对性能、外部验证和下游应用价值。例如 $\Delta\rho = 0.01$ 即使 P 值显著，也未必值得使用复杂模型。本文中 DeepGxP 不仅 P 值显著，而且从 self-gene 约 0.31 提升到约 0.68，具有明确效应量，因此更有实际意义。

58. 为什么除 P 值外还需报告效应量，如 $\Delta\rho$ ？

回答： 效应量反映差异有多大，P 值反映差异是否有统计证据。只报告 P 值无法判断提升是否足够大、是否有应用价值。 $\Delta\rho$ 直接表示 DeepGxP 相比 self-gene 的相关性提升幅度，能说明模型增益大小。对于课程项目，完整表达应包括指标、基线、数值、显著性和意义，例如“low-sGP 蛋白中 self-gene 约 0.14，DeepGxP 约 0.64， $\Delta\rho$ 约 0.46，说明复杂调控蛋白最受益于全转录组建模”。

59. 多重检验校正为什么重要？

回答： 当同时对许多蛋白、基因或通路做统计检验时，即使所有零假设都成立，也会有一部分结果因随机波动得到小 P 值。多重检验校正用于控制假阳性率，例如使用 FDR 或 Bonferroni 方法。本文涉及大量蛋白、GO/Reactome 通路和生存相关分子筛选，如果不校正，多数显著通路可能只是偶然结果。课程项目中，即使不完整复现校正，也应在讨论中说明多重检验是高维组学分析的基本要求。

60. Cox 回归中的 HR 表示什么？

回答： HR 即 hazard ratio，风险比，表示某个变量变化对应事件瞬时风险的相对变化。HR 大于 1 表示变量升高与更高事件风险相关，通常对应较差预后；HR 小于 1 表示风险降低，可能有保护作用；HR 等于 1 表示风险无明显变化。在本文 Figure 4 中，Cox 回归用于评估基因表达、真实蛋白丰度或预测蛋白丰度与 ER+ BRCA 总体生存的关系，例如 p53 蛋白高丰度与较差生存相关。

61. KM 曲线和 Cox 回归分别适合展示什么信息？

回答： Kaplan-Meier 曲线适合可视化不同组别随时间变化的生存概率，例如按 p53 预测蛋白丰度高低分组后比较两条生存曲线是否分离。Cox 回归适合量化变量对事件风险的影响，可以输出 HR、置信区间和 P 值，还可以纳入多个协变量进行调整。简单说，KM 更直观展示分组生存差异，Cox 更适合统计建模和风险量化。两者联合使用能让临床结论更完整。

62. DeepGxP 性能高于 self-gene 最直接说明什么？

回答： 最直接说明：蛋白丰度不能简单由自身 mRNA 表达完全代表，全转录组表达中包含额外的蛋白预测信息。DeepGxP 利用多个基因的表达模式，可以捕捉细胞状态、通路活性、转录后调控、翻译效率和蛋白稳定性等间接信号，因此比 self-gene 更接近真实蛋白丰度。这个结论是本文的核心逻辑基础。

63. low-sGP 蛋白提升更明显，如何从机器学习角度解释？

回答： low-sGP 蛋白的自身 mRNA 与蛋白丰度相关性低，说明单一特征不足以解释输出。从机器学习角度看，这类蛋白更可能依赖多特征、非线性和高阶交互，因此全转录组深度模型有更大提升空间。high-sGP 蛋白本来就可以被 self-gene 较好解释，模型提升空间较小；low-sGP 的 baseline 低，DeepGxP 若能捕捉其他调控信号，就会表现出更大的 $\Delta\rho$ 。

64. 如何区分模型学到真实关系还是数据集偏差？

回答： 需要通过多层验证。第一，使用严格 train/test 划分和无泄漏预处理。第二，使用 Y-scrambling 负对照检验随机标签是否仍能得到高性能。第三，使用 ICGC 等外部队列验证跨数据集泛化。第四，进行 leave-one-cancer-out 或分癌种分析，检查模型是否只学到癌种标签。第五，用 DeepEnrich 检查关键基因和通路是否符合已知生物学机制。第六，进行实验扰动或独立蛋白检测验证。只有统计预测、外部泛化和生物学解释共同支持时，才更可能是真实关系。

5 五、结果可视化与课堂讨论

65. 密度曲线图适合展示什么结果？Figure 1B 如何解读？

回答： 密度曲线适合展示某个指标在多个对象上的整体分布，例如每个蛋白的 Pearson 相关性分布。Figure 1B 比较了随机 mRNA-protein 对、self-gene/protein 对和 DeepGxP 预测蛋白/真实蛋白三类相关性分布。随机对通常集中在 0 附近，self-gene 分布中位数约 0.31，DeepGxP 分布明显右移，中位数约 0.68。这说明模型预测与真实蛋白更一致，且整体优于直接用自身 mRNA 表示蛋白。

66. 曲线整体右移在模型性能比较中代表什么？

回答： 曲线整体右移表示该组结果的数值整体更高。在模型性能比较中，如果 Pearson 相关性分布右移，说明更多蛋白获得了更高预测相关性，模型整体表现更好。右移比只看单个平均值更有说服力，因为它说明提升不是个别蛋白造成的，而是分布层面普遍改善。Figure 1B 中 DeepGxP 曲线相对 self-gene 右移，支持全转录组预测优于单基因基线。

67. 柱状图加误差线适合展示什么类型的模型比较？

回答： 柱状图加误差线适合展示多个模型在重复实验、交叉验证或多个随机种子下的平均性能和波动范围。例如 Figure 1C 用它比较 DeepGxP、XGB、SVM、VAE、ResNet、LR、mLR、CCA 等方法的 10-fold CV 平均 Pearson。柱高表示平均性能，误差线表示标准差或不确定性。读图时既要看谁最高，也要看波动是否大、差异是否稳定。

68. 模型性能柱状图中误差线很大说明什么？

回答： 误差线很大说明模型性能不稳定，可能对数据划分、随机初始化、训练过程或特定样本组成敏感。它也可能表示不同折之间样本难度差异大，例如某些折包含更难预测的癌

种或蛋白。若一个模型平均值较高但误差线很大，实际可信度不一定高。需要进一步检查交叉验证每折结果、外部验证表现和是否存在过拟合。

69. 预测值-真实值散点图中，点越接近对角线说明什么？

回答：点越接近对角线，说明预测值越接近真实值，模型数值校准越好。如果点云沿对角线分布且相关性高，表示模型既能预测相对排序，也能较好预测绝对丰度。若点云有趋势但整体偏离对角线，可能 Pearson 高但 MSE 较大。Figure 2B/C 用散点图比较 self-gene 与 DeepGxP 对 ER α 、HSP70 的预测效果，直观显示 DeepGxP 的点云更接近真实蛋白变化。

70. 散点图出现明显离群点可能代表什么？

回答：离群点可能代表真实生物学异常样本，也可能是技术噪声或数据错误。生物学上，可能是某个样本存在突变、拷贝数改变、特殊癌种背景或通路异常激活，使 RNA-protein 关系偏离常规。技术上，可能是样本 ID 错配、测序质量差、蛋白测量异常或批次效应。处理离群点时不能直接删除，应先检查数据质量和样本注释，再判断是否具有生物学意义。

71. 小提琴图相比箱线图多展示哪些分布信息？

回答：小提琴图除了显示中位数和四分位范围，还展示数据在不同数值区间的密度形状。宽的地方表示该数值附近样本或蛋白更多，窄的地方表示更少。箱线图更简洁，适合看中位数、四分位数和离群点；小提琴图更适合观察分布是否偏态、是否多峰、组间分布形状是否不同。Figure 2 中用小提琴图展示不同分组的 $\Delta\rho$ 分布，有助于判断提升是否集中在某些蛋白还是整体分布变化。

72. 小提琴图中“宽”的部分代表什么？

回答：小提琴图中宽的部分代表该数值附近的数据密度较高，也就是更多观测值集中在这个范围。比如某组 $\Delta\rho$ 的小提琴图在 0.4 附近较宽，说明很多蛋白的提升幅度集中在 0.4 左右。读小提琴图时不能只看最高点，还要看整体宽窄、中心位置和尾部，判断分布是否集中、偏态或存在长尾。

73. 箱线图的中位数、四分位数和离群点如何解释？

回答：箱线图中间的横线是中位数，表示一半数据高于它、一半低于它。箱体上下边界通常是第一四分位数和第三四分位数，包含中间 50% 的数据。箱线外的须表示主要数据范围，离群点表示远离主体分布的观测值。中位数用于比较典型水平，箱体高度表示离散程度，离

群点提示异常样本或特殊对象。在蛋白预测中，箱线图可以快速比较不同 protein class 的相关性或提升幅度。

74. 折线图适合展示 BRCA 样本增量实验的哪些信息？

回答： 折线图适合展示模型性能随加入 BRCA 样本数量变化的趋势。横轴是加入训练的 BRCA 样本量，纵轴是 Pearson 相关性或其他性能指标。它可以显示性能是否随样本量增加而提升、提升是否线性、是否存在 turning point、是否进入平台期。本文 BRCA 增量实验中，约 60 个样本附近出现性能转折点，说明特定癌种样本达到一定数量后能明显改善该癌种预测。

75. 折线图出现平台期说明继续增加样本可能带来什么变化？

回答： 平台期说明继续增加样本带来的边际收益变小。可能原因是模型已经学到该癌种主要 RNA-protein 关系，剩余误差来自不可由 RNA 解释的因素、标签噪声或模型容量限制。此时继续增加同类样本可能仍有小幅提升，但不如引入新特征、多组学数据、改进模型或提高标签质量有效。平台期也可用于估计实际项目中样本量投入的性价比。

76. Kaplan-Meier 生存曲线中两条曲线分离说明什么？

回答： 两条 KM 曲线分离说明两组患者的生存概率随时间变化不同。例如高 p53 蛋白组曲线更低，表示该组事件更早或死亡风险更高，预后较差。曲线分离越明显，组间生存差异越直观。但是否显著还需要 log-rank 或 Cox P 值支持，并结合样本量和删失情况解释。KM 曲线主要展示分组差异，不等同于因果关系。

77. HR forest plot 中置信区间跨过 1 通常表示什么？

回答： HR 的置信区间跨过 1 通常表示该变量与事件风险的关联在统计上不显著，因为 HR=1 代表无风险差异。如果 95% CI 包含 1，说明数据不能排除“无影响”的可能。若 HR>1 且置信区间完全大于 1，通常表示风险升高；若 HR<1 且置信区间完全小于 1，通常表示风险降低。Forest plot 既要看点估计，也要看置信区间宽度，宽区间说明不确定性大。

78. UMAP 为什么不能单独作为模型性能指标？

回答： UMAP 是非线性降维和可视化方法，主要用于直观展示高维数据结构。它受参数、邻居数、随机种子、输入特征和预处理影响较大，二维距离不一定严格反映真实高维距离。因此 UMAP 图看起来分得开，不能单独证明模型性能好。应结合定量指标，例如 Pearson

预测相关性、NMI、ARI、分类准确率或 marker 表达一致性。Figure 5F 中 UMAP 是应用展示，NMI/ARI 才提供更定量的聚类一致性评价。

79. NMI 和 ARI 在聚类评价中分别衡量什么？

回答： NMI 即归一化互信息，衡量聚类标签与真实细胞类型标签之间共享了多少信息，越接近 1 表示聚类包含越多真实标签信息。ARI 即调整兰德指数，衡量任意两个样本在聚类结果和真实标签中是否被一致地分到同组或不同组，并校正随机一致性。NMI 对聚类数差异相对宽容，ARI 对过度拆分和过度合并更敏感。二者联合使用能更可靠评价单细胞聚类效果。

80. 如果重新设计一张总览图，如何整合数据、模型、评价、解释和应用？

回答： 总览图可以设计成从左到右的闭环流程。第一层是数据：TCGA RNA/RPPA、ICGC、CITE-seq。第二层是模型：DeepGxP 输入 RNA，输出总蛋白、磷酸化蛋白和表面蛋白。第三层是评价：Pearson、MSE、10-fold CV、外部验证和 $\Delta\rho$ 。第四层是解释：Integrated Gradients 计算基因贡献，定义 pLEG/nLEG，再做 GO/Reactome 富集。第五层是应用：ER+ BRCA 生存分析、EGFR/HER2 磷酸化通路解释、CITE-seq 细胞分群。图的核心信息应是“RNA → 蛋白预测 → 机制解释 → 临床和单细胞应用”。

6 六、综合讨论题

81. 如果要把本文设计成一个完整机器学习项目，你会如何定义研究目标、数据集、模型、基线、评价指标和最终结论？

回答： 研究目标可以定义为：利用 RNA 表达数据预测蛋白及磷酸化蛋白丰度，并解释预测背后的调控基因和通路。数据集方面，TCGA pan-cancer RNA/RPPA 用于训练、验证和内部测试，ICGC 用于外部验证，PBMC/CBMC/H1N1 CITE-seq 用于单细胞扩展。模型方面，核心模型是 DeepGxP，一维 CNN 多输出回归；解释框架是 DeepEnrich。基线包括 self-gene、LR、mLR、CCA、XGBoost、SVM、VAE、ResNet 和 Y-scrambling。评价指标包括 Pearson、MSE、 $\Delta\rho$ 、交叉验证均值标准差、Cox P、HR、NMI 和 ARI。最终结论是：全转录组深度学习能比单个 mRNA 更准确预测蛋白层信息，尤其对 low-sGP 和磷酸化蛋白更有价值，并可通过解释性分析、生存分析和单细胞任务体现下游应用价值。

82. DeepGxP 的性能提升究竟来自模型结构、全转录组输入，还是数据规模？你会设计哪些实验来区分这些因素？

回答：可以通过三组消融实验区分。第一，控制模型结构，改变输入：比较 self-gene、随机等量基因、通路基因、全转录组输入，判断提升是否来自全转录组信息。第二，控制输入，改变模型：用同一全转录组输入比较 LR、mLR、MLP、CNN、XGBoost、Transformer，判断 CNN 结构是否带来额外优势。第三，控制输入和模型，改变训练样本量：绘制 learning curve，比较 10%、25%、50%、100% 样本下性能变化，判断数据规模贡献。还可以加入 no-self-gene、随机基因顺序、leave-one-cancer-out 和 Y-scrambling。只有这些实验组合起来，才能说明性能提升分别来自信息量、模型表达能力和样本规模，而不是单一因素。

83. 如果模型在某些癌种表现很好、某些癌种表现较差，应如何判断这是生物学差异、样本量问题还是数据偏差？

回答：需要分层排查。若某癌种样本量很小，且性能随样本增加明显提升，说明样本量可能是主因。若样本量足够但特定蛋白在该癌种中表达很低或变异小，可能是生物学可预测性不足。若外部队列中同一癌种表现差，而内部测试好，可能是数据平台或批次偏差。具体方法包括：比较各癌种样本量、蛋白表达方差、self-gene correlation、标签质量、癌种内外部验证、BRCA 类似样本增量曲线、leave-one-cancer-out 实验和批次校正前后结果。最终应把原因拆成数据规模、标签质量、癌种生物学和平台偏差四类讨论。

84. 预测蛋白可以用于临床预后分析，但不能替代真实蛋白检测。这个边界在项目报告中应该如何表达？

回答：项目报告中应明确写成：DeepGxP 预测蛋白是基于 RNA 的研究性推断，可用于补全 RNA-seq 队列中的蛋白层信息、提出候选预后标志物和生成机制假设，但不能作为临床诊断、治疗决策或靶向药选择的直接依据。临床决策仍需要 IHC、FISH、RPPA、质谱或其他经过验证的真实蛋白检测。以 p53 为例，预测 p53 蛋白与生存相关说明模型有研究价值，但要进入临床还需要独立队列、前瞻验证、真实蛋白检测对照和标准化阈值。简洁表达是：预测蛋白适合“发现和辅助分析”，不适合“替代检测和直接决策”。

85. 如果要构建 RNA-Protein 预测关联网络，你会如何定义节点、边、边权重和网络验证方式？

回答：可以定义两类节点：RNA 基因节点和蛋白节点。边表示某个基因对某个蛋白预测有贡献，可由 Integrated Gradients、SHAP、模型权重或消融性能下降定义。边权重可以设为标准化 IG 分数、平均贡献值、去除该基因后的 $\Delta\rho$ 下降，或跨交叉验证稳定出现的频

率。正权重表示正向预测贡献，负权重表示负向预测贡献。网络验证可从三方面进行：第一，统计验证，检查边在不同随机种子和数据划分中是否稳定；第二，生物学验证，检查边是否富集于已知通路、PPI、转录因子靶基因或 kinase-substrate 数据库；第三，实验验证，对关键基因进行 CRISPR/RNAi/药物扰动，再测目标蛋白变化。

86. DeepEnrich 发现的关键基因和通路是否具有生物学机制意义？如何设计计算验证和实验验证来增强可信度？

回答：DeepEnrich 结果具有机制假设意义，但不能单独证明因果机制。计算验证方面，可以检查 pLEG/nLEG 在不同交叉验证折、随机种子和外部队列中的稳定性；使用不同 IG 阈值、SHAP、permutation importance 等替代解释方法比较一致性；将关键基因与 GO/Reactome、PPI、kinase-substrate、TF-target 数据库交叉验证；并做 no-self-gene 或通路基因消融实验。实验验证方面，可以选择高贡献基因进行 CRISPR knock-out、RNAi knock-down、过表达或药物抑制，再通过 Western blot、RPPA、质谱或流式检测目标蛋白或磷酸化蛋白变化。若计算稳定性和实验扰动都支持，机制可信度会显著提高。

87. 如果要把本文从 bulk RNA-seq 扩展到单细胞、多癌种或药物反应预测，最大的方法学挑战是什么？

回答：扩展到单细胞的最大挑战是 dropout、稀疏性、批次效应和细胞类型组成差异；扩展到多癌种的挑战是癌种异质性、样本不平衡和 lineage-specific regulation；扩展到药物反应预测的挑战是药物标签噪声、处理时间、剂量差异、细胞系与患者样本差异，以及蛋白活性是否真正介导药物敏感性。共同的方法学难点是跨域泛化：模型不能只在训练队列有效，还要在不同平台、不同组织、不同实验条件下稳定。可能解决方向包括多组学整合、domain adaptation、层级模型、图神经网络、通路先验和严格外部验证。

88. 在复现论文时，如果没有完整原始数据或计算资源有限，如何设计一个简化但仍有教学价值的复现实验？

回答：可以设计最小教学复现。数据上选择一个癌种或一个小型公开 CITE-seq 数据集，只保留若干高质量蛋白和几千个高变基因。模型上先实现 self-gene baseline、mLR/XGBoost 和一个简化 MLP 或 1D-CNN。评价上报告每个蛋白 Pearson、MSE、 $\Delta\rho$ ，并画预测值-真实值散点图和相关性分布图。解释上选一个蛋白做 feature importance 或 IG，再做简单 GO 富集。最终目标不是完全复现论文所有数值，而是复现核心逻辑：RNA 输入、蛋白标签、基线比较、模型提升、解释和局限讨论。这样即使算力有限，仍有完整教学价值。

89. 如果模型结果与论文不一致，如何从数据预处理、划分方式、模型参数、随机种子和评价代码等方面系统排查？

回答： 排查应按固定顺序进行。第一，数据预处理：检查样本 ID 是否正确配对，基因和蛋白筛选标准是否一致，标准化是否只在训练集拟合，缺失值处理是否正确。第二，划分方式：确认训练、验证、测试和交叉验证折是否与论文一致，是否发生样本泄漏。第三，模型参数：核对输入维度、卷积核数量、kernel size、stride、pooling、dense 层、激活函数和输出维度。第四，训练设置：核对 learning rate、batch size、epoch、optimizer、early stopping、dropout 和 seed。第五，评价代码：确认 Pearson 是按蛋白跨样本计算，预测值和真实值索引对齐，统计检验对象正确。最后，用一个小数据子集做端到端 sanity check，确保流程无误。

90. 作为期末项目汇报，你会选择哪三张图最能讲清楚数据、模型性能和研究结论？为什么？

回答： 我会选择三张图。第一张是整体 pipeline 图，整合 TCGA/ICGC/CITE-seq 数据、DeepGxP 模型、DeepEnrich 解释和临床/单细胞应用，用于让听众快速理解研究设计。第二张是 Figure 1B/C 或自制模型性能比较图，展示 DeepGxP 相比 self-gene 和其他模型的核心性能优势，这是论文最基础的证据。第三张选择 Figure 3 或 Figure 4/5，视汇报重点而定：如果强调机制解释，选 Figure 3，说明 DeepEnrich 能把模型连接到细胞周期、MAPK 等通路；如果强调应用价值，选 Figure 4 的 p53 生存分析或 Figure 5 的单细胞 CD16/UMAP，说明预测蛋白具有临床或单细胞表型意义。三张图分别覆盖“任务是什么、模型是否有效、结果为什么有价值”。

结语

这 90 个问题的核心不是背诵论文细节，而是建立完整机器学习科研项目的思维链条：任务定义、数据处理、模型与基线、训练质控、统计评价、可视化解释、外部验证和研究边界。对于期末项目，最重要的是把“模型性能提升”讲成一条证据链，而不是只堆结果数值。